

大型語言模型應用在詐騙偵測之研究

摘要

隨著人工智慧技術的快速發展，詐騙手法變得更加複雜，對個人資訊安全帶來了嚴峻的挑戰。許多詐騙案例利用情感需求與話術包裝，隱藏關鍵字來誘導受害者提供金錢或個人資料。科技進步的同時，也更加突顯大眾需要提升資安意識與運用先進技術偵測詐騙的重要性。

本研究主要探討大型語言模型（Large Language Model, LLM）與傳統機器學習模型（Machine Learning, ML）於詐騙訊息偵測任務上的效能差異，並分析其對於情緒操控字眼與隱性詐騙關鍵字的判斷能力。研究者以 TF-IDF 結合 Logistic Regression 作為基準模型，評估其在小樣本資料下的分類效果；同時採用 Gemini、Mistral 等雲端 LLM 以及本地端微調之 Qwen-LoRA，透過提示詞設計與參數微調進行優化。為確保比較時的公平性，所有模型皆以相同資料集之獨立測試集進行評估，並使用 Accuracy、Precision、Recall、F1-score 與 AUC 指標作為效能衡量基準。

實驗結果顯示，傳統機器學習模型在語意變化豐富時的詐騙文本中表現受限，而經過 LoRA 微調後的 Qwen 語言模型，在召回率與 AUC 指標上均達顯著領先，能更準確捕捉隱含的詐騙語氣與語意特徵。本研究結果證實 LLM 結合微調策略能有效提升詐騙檢測效能，並具備應用於實際防詐系統的可行性。研究成果不僅能應對多樣化的詐騙情境，還可作為其他資訊安全場域的技術參考，提高資安防護的實際應用。

研究動機與研究問題

詐欺犯罪在近年持續攀升，根據警政統計通報(2024)，112 年詐欺犯罪大約有 3.8 萬件，相比於前一年增加了 8,314 件，相當於增加了 28.17%，其中以「投資詐欺」相較於前一年增加了 5,233 件為最多的一項。各年齡層的被害人其案件類型皆不同，警方也依照年齡分眾進行強化宣導，可見詐騙議題被高度重視。根據曾開源檢察官所說，全世界一年的被詐騙金額高達 1500 億新台幣，相當於台灣第三大金控一年的營收，顯示詐騙議題具有高度社會與經濟方面的衝擊。

表 1、各年齡層最常見詐騙類型(警政統計通報，2024)

被害人年齡	最多被詐騙類型
未滿 18 歲	假網路拍賣(購物)
18-29 歲	解除分期付款詐欺(ATM)
30 歲以上	投資詐欺

根據李佩嫻、顧以謙(2023)，目前誘導式詐騙的案例很多，數位化時代發展出眾多交友 APP，這些雖然方便交友，卻也容易成為愛情詐騙的管道。一些詐騙集團有組織地以尋找長期伴侶讓受害者自願轉帳，以騙取大額財產和造成情感上的依賴與傷害。其中隱晦的誘導式詐騙關鍵字和情緒上的恐嚇、勒索，刻意迴避警示字詞，使受害者難以發現詐騙的真相。傳統以關鍵字匹配與固定模板為基礎的詐騙偵測系統，面對這類變化多端的語境往往效果不佳，準確率與召回率均有待提升。隨著詐騙模式日益隱蔽與多樣化，單純依賴表層特徵之方法已面臨挑戰。在實務層面，企業導入詐騙偵測系統時，除了模型效能外，同時需考量部署成本、推論效率、誤判風險以及系統可維護性等因素。因此，系統性比較生成式 AI 與傳統機器學習模型在詐騙偵測任務上的效能差異與錯誤型態，不僅具有技術層面的意義，更能提供企業在模型選型與風險控管上的實證依據，並作為未來防詐技術發展方向之參考基礎。

目前 LLM 在詐騙檢測中的研究仍處於初步階段，許多 LLM 主要應用於一般自然語言處理 (Natural Language Processing, NLP) 任務，而缺乏針對隱性詐騙話術與情感操控的有效偵測。支援向量機 SVM(support vector machine)和人工神經網路 ANN(Artificial Neural Network) 是用於欺詐檢測的常用 ML 演算法 (Ali, 2022)，而在王厚勛(2020)文本分類基本上透過 TF-IDF (Term Frequency–Inverse Document Frequency)，但這些方法在應對隱性詐騙話術、情緒操控時表現不佳。本研究旨在提升防詐騙系統的檢測準確度，通過比較機器學習技術和大型語言模型來優化詐騙識別過程，希望驗證 LLM 在非結構化詐騙語境中是否能提升詐騙偵測的準確率。

本研究為了避免盲目追逐生成式 AI，將聚焦於以下核心研究問題：

RQ1. 雲端大型語言模型在詐騙偵測任務中的表現是否優於傳統機器學習 Baseline

使用相同資料集去檢驗不同的模型，對比 gemini 和 mistral 等雲端模型與傳統機器學習 TF-IDF 結合 Logistic Regression 在 Accuracy、Precision、Recall、F1、AUC 指標檢測其分類是否為詐騙的表現。用以驗證 LLM 在此領域的是否一開始就具備顯著優勢，確立後續研究的價值。

RQ2：分析雲端 LLM 與傳統 Baseline 模型在語意線索擷取與語境推論能力上的質性差異為何

本問題主要檢視傳統 ML 是否會傾向依賴字面上的關鍵字特徵，而 LLM 是否能相比於機器學習，更有效捕捉隱含於語境中的詐騙意圖與語意線索。解釋 RQ1 中效能差異的成因，剖析 LLM 在深層語意理解上的優勢。

RQ3：落地並微調後的小模型與雲端模型在效能、推理速度與成本上的差異

評估模型落地的可行性。比較雲端 LLM 與本地端微調後小模型的準確率、推理速度、運算資源需求和成本效益，評估是否有建置本地端微調 LLM 的實際價值。透過實驗驗證建置專門化、本地化防詐模型的實際價值，為企業或政府單位提供兼顧資料隱私與效能的系統設計參考。

RQ4：微調後的小模型再加上情緒分類，情緒操控偵測與情緒類型辨識任務中的模型表現差異

比較 LLM 與 ML 在情緒語用線索下的辨識能力、錯誤型態與敏感度差異，以分析不同模型在複雜情境中，情緒訊號的優勢與限制，並說明情緒操控線索對詐騙辨識行為的影響。

文獻回顧與探討

近年來，詐騙手法的多樣化，使得傳統的詐騙檢測方法面臨挑戰。現有的防詐騙技術主要依賴機器學習的方法，如 TF-IDF、SVM、隨機森林 Random Forest 等，來識別詐騙關鍵字與模式。根據王厚勛(2020)發現以 DistilBERT 搭配隨機森林的分類準確率高達 98.7%。然而，這些方法依賴人工標註的特徵工程，難以適應詐騙話術的不斷變化，且對隱性詐騙字眼與情感操控手法的辨識能力推測是有限的（陳怡文，2021）。

近年，大型語言模型在自然語言處理領域的發展，為詐騙檢測提供了新的可能性。Korkanti（2024）研究發現，LLM 在分析非結構化數據方面具有顯著優勢，能夠識別語境中的異常模式，提升金融詐騙檢測的準確率，還揭示了傳統方法所忽視的複雜欺詐計劃。根據 Li et al. (2024) 的研究，BERT 在詐騙文本分類的準確率為 91.3%，而 GPT-4 則可達到 94.7%。

2.1 LLM 選擇與應用

在選擇大型語言模型進行詐騙檢測與情感分析設計時，通常考慮其有效性、效率和與專家工作流程的整合(Li et al., 2024)。根據 Chakraborty(2024) 發現雖然不同 LLM 在個人欺詐和濫用的檢測任務中都表現良好，但他們在其他任務中的差異很大，尤其是在需要細緻入微的語用推理任務中。根據 Han et al. (2024)，目前適合涵蓋多樣化的任務與應用場景的 LLM 主要可分為以下三類：

1. 通用 LLM：具備強大的文本理解與生成能力，但運行成本高，推理速度較慢，適合雲端部署或 API 調用。
2. 輕量級 LLM：在計算資源有限的情況下，可在本地運行，能夠兼顧準確率與成本效益。
3. 專門 NLP 模型：特定任務以這兩種方法去嘗試微調後，能夠高效處理詐騙文本，適合部署於即時檢測系統。

◆ 挑選 LLM 的關鍵指標

1. 性能 Capacity：LLM 的性能通常由其參數量、處理能力和支持的 token 數量來衡量（Han et al., 2024）。較大參數量的模型通常能提供更高的語言理解與推理能力，適用於複雜的任務，不過要在輸出品質和易用性之

間取得平衡，使 LLM 可以接受大量且廣泛的使用者訪問。（Li et al., 2024）。

2. 準確度 Accuracy：Yoon(2023) 在技術信用評估標準範圍內準確理解使用者查詢的準確性為 92%，推估我們在進行詐騙檢測和情感分析時，確保模型的準確度是關鍵，且須至少高於 95%，才能快速、輕鬆地確定技術可靠性。
3. 推理速度與延遲 Inference Speed and Latency：研究顯示，GPT-4 推理速度平均在 2-5 秒，而小型 LLM 以 Llama 3 8B 為例，可在 1-2 秒內完成判斷，但其準確率可能略低（Han et al., 2024）。

2.2 資源需求與本地運行

在選擇 LLM 進行詐騙檢測時，考量模型效能、推理速度和運行成本。如果選擇雲端 LLM，則根據 token 使用量計價評估 API 調用的成本。例如 OpenAI GPT-4 Turbo 每 1 千 tokens 約\$0.01~\$0.03 美元，而 Claude 3 雖然有提供部分可免費使用，不過仍需控制請求量以避免高昂費用。雲端 api 提供即時性的推理與強大計算能力，但相比於本地端的運行，雲端 LLM 會有 API 延遲與隱私性問題。

若研究後續將在本地運行 LLM，則需再評估硬體資源與運行效能。舉例較小的開源模型如 Mistral 7B、Llama 3 8B 適用於中小型應用場景，但大型模型如 Llama 3 70B，則需要 A100 或 H100 GPU，這對於研究而言，可能會帶來較高的設備與電力成本。

因此，選擇適合的 LLM 應依據效能需求、運行效率與成本進行權衡，在短期研究或快速測試時優先使用雲端 LLM API，降低前期開發成本，確保能快速取得結果。後續長期運行則考慮本地 LLM，透過輕量化技術減少 GPU 計算需求。根據不同應用場景，系統要即時偵測詐騙訊息，則雲端 LLM 更適合。若需處理大量歷史數據，使用本地 LLM 比較具有成本效益。根據 Ji, F., & Kim, D.(2025)，生成式 AI 在詐騙與偵測任務中展現出多種應用模式。例如在 phishing 偵測任務中，研究者比較了 GPT-4、Gemini 與多款開源模型 Qwen、Llama 在釣魚網站辨識上的表現。因此本研究將開源模型 Qwen 與 Gemini 加入實驗進行比較。本研究將根據以上考量因素，評估不同 LLM 模型在詐騙檢測中的適用性。

2.3 Qwen 模型與 LoRA 微調在下游任務中的可行性

為了在大型語言模型上實現高效微調，本研究採用 Low-Rank Adaptation 方法。LoRA 透過低秩矩陣更新，大幅降低微調所需的計算與記憶體成本，並在多種自然語言處理任務中證明了其有效性。Surikova 和 Sabidaeva (2025) 的比較研究顯示，在多任務設定下，LoRA 能夠有效微調大型語言模型，且在分類任務中的表現可與全參數微調相近，為本研究中採用 LoRA 微調 Qwen 模型提供了實證依據。而 Guo et al. (2026) 在本地部署 LLM 的研究中以 Qwen + LoRA 為實驗對象，證實該組合在推理速度與部署效能方面具可操作性，進一步支持本研究在詐騙文本分類任務中微調 Qwen 模型並進行性能比較的可行性。綜合而言，這些研究為本研究使用 Qwen + LoRA 在下游分類任務中的可實驗性提供了理論與方法依據。

2.4 LLM 微調與情緒分析的結合

中文自然語言處理中的情感分析在多個領域中起著重要的角色，但是中文的多義性、語意的模糊性和情感表達的細微差別都讓模型在辨別詐騙時需要突破多重困難。詐騙話術不僅涉及關鍵字識別，也包含情緒操控，如利用恐懼、緊迫感、信任建立等策略來欺騙受害者（池晉煒，2022）。然而，傳統 ML 方法難以識別這類語境特徵，需要透過引入多種注意力機制，包括全局語境、局部語性、上下文注意力做模型優化，從而提升辨識情感誘導式的詐騙。在研究者專題中的 ML 模型根據 Sun, Bao & Bu (2022) 研究，透過 BERT + TF-IDF 結合，可以提高中文文本分類的效果，根據文本特徵結合專有名詞的資訊及其上下文話語對其進行分類，推測可提升詐騙語句的語意分析能力，使模型能夠更準確地識別詐騙模式。

在 LLM 提示詞修改時加入輸出原文可能誘導詐騙者產生的情緒，讓使用者意識到自己誤入詐騙者的陷阱，延緩做決策的時間與更加理性思考。在 LLM 微調中，參考檢測詐騙與情感分析的資料檢索(Data Retrieval)和性能需求。系統需要從資料庫或外部資料源檢索相關文本進行分析，而檢索的資料量會影響模型的處理時間和效率。在處理長文本或大量資料時，需要將文本分塊處理（chunking），以便在處理時不會超出模型的上下文限制，同時保證每個塊（Chunk）內的語境能夠被正確理解。對於即時詐騙檢測和情感分析系統，回答速度(Response Time)至關重要。如果速度過慢，可能會降低用戶的滿意度，並影響實際應用中的效能，尤其是在需要即時反應的情境中。Han et al. (2024) 提出，透過 LoRA (Low-Rank Adaptation) 與 PEFT (Parameter Efficient Fine-Tuning) 技術，可在低計算資源下高效微調 LLM，推論可適用於情感分析與詐騙檢測任務。

現有研究顯示，傳統 ML 方法在關鍵字檢測方面仍具備一定優勢，尤其是在特定領域的詐騙語料上具有較高準確率（陳恩齊，2019）。然而，LLM 在語境理解、情感分析與隱性詐騙檢測上表現更佳，且具備更高的適應性。根據 (Papavasava, 2024) 應用基於 AI 的模型進行在線欺詐檢測和分析，應研究構建能夠捕獲新出現的欺詐模式的基於 AI 的模型。

研究方法及步驟

3.1 研究方法

本研究使用實驗法，以量化方式比較大型語言模型與傳統機器學習模型於詐騙訊息偵測任務上的效能差異。將資料集依照分層抽樣方式切分為訓練集、驗證集與獨立測試集，並讓所有模型皆於相同測試集上進行效能比較，以確保結果具可比性。

研究選用的比較模型包含作為傳統機器學習 Baseline 的 TF-IDF + Logistic Regression，代表以詞頻為特徵的詐騙檢測方法。大型語言模型方面，使用到呼叫 api 方式，透過 OpenRouter 網站進行比較成本與 Latency 分為 gemini-2.5-pro 與 mistral-large-latest 兩種進行測試，以修改 LLM 的提示作為優化方法。

最後，考量實務部署的硬體限制與成本效益，在本地端將使用以 Qwen/Qwen2.5-1.5B-Instruct 輕量型 LLM，參數規模為 1.5B，並在 NVIDIA RTX 4060（8GB VRAM）環境下進行微調與推論。

為降低模型訓練成本並提升少量樣本情境下的適應能力，本研究採用 Low-Rank Adaptation 方法進行參數微調，使模型可以學習詐騙文本中特定的語意模式與情感線索。模型輸入文本的最大長度設定為 512 tokens，此設定能涵蓋大部分詐騙對話內容，同時避免因序列長度過長導致 GPU 記憶體不足或推論效率下降。

評估指標包含 Accuracy、Precision、Recall、F1-score、Specificity，以及 AUC-ROC 與 AUC-PR，並透過 ROC 曲線與 Precision-Recall 曲線進行整體比較分析。

3.1.1 Google Gemini 2.5 Pro

Gemini 2.5 Pro 是 Google 推出的多模態模型，其最具代表性的參數為高達 1,048,576 Token (1M) 的超大規模 Context Size。該模型採用混合專家架構 (MoE)，並具備原生多模態處理能力。在長文本分析中，1M Token 的容量允許本研究置入大量的詐騙樣本案例作為 Few-shot 提示，而不用擔心記憶溢出。

3.1.2 Mistral Large Latest

Mistral Large 是 Mistral AI 開發的最頂級封閉原始碼模型，目前在 OpenRouter 上的版本支援約 262,144 Token (262K) 的 Context Size。雖然其上下文容量略遜於 Gemini，但 Mistral Large 以極高的指令遵循度 (Instruction Following) 與推理效率聞名。其架構針對多語言進行了深度優化，對於結構化提示詞 (Structured Prompting) 的反應極為靈敏。在 OpenRouter 的定價體系中，Mistral Large 的輸出成本低於 Gemini，且在處理中短篇幅文本時，通常展現出更低的延遲，適合對於即時性要求較高的檢測場景。

3.1.3 Low-Rank Adaptation

Low-Rank Adaptation 是一種參數高效化微調方法，透過低秩矩陣分解，僅微調少量參數，可以明顯降低成本並保持原模型推理能力。可以避免重新訓練整體模型權重，降低 GPU 計算成本和增強模型對新型詐騙的適應能力。

3.1.4 逼近理想解排序法

TOPSIS (Technique for Order Preference by Similarity to Ideal Solution，逼近理想解排序法) 是一種多準則決策分析方法，由 Hwang & Yoon (1981) 提出。TOPSIS 的核心思想是，每個模型的最佳表現應接近理想解，即各指標的最優值，同時遠離各指標的最差值，負理想解。從而通過計算模型與理想解和負理想解的距離來進行排序。具體方法包括以下步驟：

首先，將各模型在 F1-score、AUC、Recall、Precision 與 Specificity 等指標上的原始數據進行向量歸一化，以消除不同單位或數值範圍之間的影響。其次，對歸一化後的數據乘以權重，形成加權決策矩陣，權重根據研究目標或進行敏感度分析設定。第三，確定理想解與負理想解，計算每個模型到理想解和負理想解的歐氏距離，進而求得接近係數 (closeness coefficient)。接近係數越接近 1，表示模型的綜合表現越優。最後，依據接近係數對模型進行排名，並

透過不同權重組合的敏感度分析檢驗排序的穩健性。TOPSIS 提供了一個客觀、可量化且兼顧多指標的模型評估方法，有助於整合各項性能指標，對模型進行全面比較（Hwang & Yoon, 1981；Behzadian et al., 2012）。

3.2 研究步驟

1. 文獻調查與初步分析

蒐集詐騙檢測相關文獻與技術資料，總結現有方法的優缺點，確認研究方向與目標。

2. 數據蒐集與預處理

本研究將使用台灣警政署詐騙案例資料以及 165 反詐騙網站等眾多政府公開資料，並透過人工標註與 TF-IDF 篩選方法建立高品質詐騙數據集，完成數據過濾，並對文本進行人工標註，以符合訓練需求。

3. 設計評估指標與提示詞實驗

因為校內擁有很多資源，可以先找尋資料制定評估詐騙檢測模型的核心指標，包括準確率（Accuracy）、召回率（Recall）、推理速度（Latency）與資源消耗，作為比較 LLM 與 ML 模型效能的依據。使用 gemini 和 mistral 測試模型在關鍵字檢測與情感操控字眼識別中的表現，記錄並分析結果。導入已處理的資料集，添加合適的 prompts 做詐騙檢測，還有對於情緒給與適當的參考定義和分數判斷。

4. 針對 Qwen/Qwen2.5-1.5B-Instruct 模型微調

本研究採用 LoRA（Low-Rank Adaptation）進行 LLM 微調，相較於全參數微調，LoRA 可減少約 80% 計算成本（Hu et al., 2023）。微調時將使用標註的詐騙文本數據，提升模型識別隱性詐騙字眼與情感操控表達的能力。

根據硬體資源與應用需求，選定 Qwen/Qwen2.5-1.5B-Instruct 模型微調進行微調，並針對詐騙特徵進行優化。本研究將參考以下技術進行微調：利用 LoRA 進行高效微調（Parameter Efficient Fine-Tuning），降低計算資源需求，同時提升模型的情感分析能力（Hu et al., 2023）。針對詐騙話術常見的恐懼訴求、威脅性語言、同理心誘導進行標註，讓 LLM 更能區分詐騙話術與正常對話。

5. 模型測試與性能比較

測試 LLM 與 ML 模型在不同數據集上的表現，記錄準確率、召回率、推理速度等指標。比較微調前後的性能差異，分析 LLM 與 ML 的效能優劣。

6. 成本與支出評估

使用雲端 llm 將試算使用 api 的成本，包括呼叫的延遲時間和付出的金錢。本地端的 Qwen+lora 將忽略硬體成本，只計算付出的時間。

7. 實驗與測試

在不同數據集上測試優化後的 LLM 模型與現有 ML 模型，評估其在準確率、召回率與推理速度等指標上的表現。分析 LLM 與 ML 的資源消耗，權衡其應用於實際場景的可行性。

8. 撰寫報告與成果總結

整理研究過程與結果，完成結案報告，並對未來研究方向與應用場景提出建議。

研究成果

4.1 資料處理

資料採用 CSV 格式，每筆資料包含原始文本與多種標註，分別對應表二中的欄位。其中 text 放入常見的詐騙話術，資料來源從 165 打詐儀錶板和警政署公開的案例擷取，聚焦在投資詐騙、求職詐騙、假冒名義與交友戀愛詐騙，詐騙話術包含資金借貸和獲取個資相關內容。將文本內容是詐騙的 label 標註 1，而非詐騙的內容則是透過人工處理，將詐騙的話術保留原意，並使用 chatgpt 生成出非詐騙的語句標註為 0。整份共包含 354 筆資料，其中人工標註詐騙話術有 180 筆，非詐騙有 174 筆。scam_semantic_type 是標註語意的類型，主要有三種:non_scam、keyword 和 implicit。emotion_manipulation 說明文本是否存在情緒操控，emotion_type 是文本欲誘導民眾可能產生的情緒類型，keyword 是文本中的詐騙關鍵字。將資料集依既有的詐騙偵測研究慣例，劃分為訓練集 training set、驗證集 validation set 與獨立測試集 test set。

表二、初始資料集

text	label	scam_semantic_type	emotion_manipulation	emotion_type	keyword
原文	詐騙 與否	詐騙語意類型	是否存在情緒操控	情緒類型	關鍵字

4.2 模型說明

4.2.1 傳統機器學習基準模型

根據研究者專題研究的機器學習模型為基準模型，採用 TF-IDF 結合 Logistic Regression 進行詐騙文本分類。文本先經過斷詞與前處理後，轉換為 TF-IDF 向量表示，再以 Logistic Regression 進行二元分類。模型僅使用文本表層特徵進行學習，未納入任何語境或情緒相關標註，以關鍵字導向方法作為比較基準。

4.2.2 雲端大型語言模型(Gemini、Mistral)

雲端大型語言模型包含 Gemini 與 Mistral，皆透過 API 呼叫方式進行推論，未進行任何參數層級的微調。模型以統一設計的提示詞（prompt）輸入原始文本，要求模型判斷該文本是否屬於詐騙訊息，並回傳分類結果。

為了避免提示詞設計影響模型比較結果，本研究對所有雲端 LLM 採用相同的輸入結構與輸出格式，只有替換模型本身。目的在於確保比較結果是反映模型語言理解與推論能力之間的差異。

Prompt 設計如圖一：

```
"""
輸入：單一文字訊息
輸出：dict，只保留和 Qwen 比較會用到的欄位：
- FraudRate: 0~100 (float)
- result: "詐騙" 或 "非詐騙"
"""

prompt = f"""
你是一個檢測詐騙訊息的系統。請閱讀下面的訊息，判斷是否為詐騙，
並估計成為詐騙的機率 (0%~100%)。

訊息：
{text}

請嚴格只用以下格式回答（不要多出任何其他文字、標點或說明）：

結果：詐騙 或 非詐騙
詐騙機率：xx%
"""
```

圖一、大型語言模型提示詞設計

4.2.3 本地端 LoRA 微調模型

本研究選用 Qwen2.5-1.5B-Instruct 作為本地端大型語言模型基礎，並採用 Low-Rank Adaptation (LoRA) 進行參數高效化微調。微調過程透過更新少量參數，使模型能在有限 GPU 資源下學習詐騙文本的語意模式。

微調模型使用與雲端 LLM 相同的文本輸入格式進行訓練，並在推論階段先由模型產生詐騙判斷結果，再額外計算詐騙機率值，以利後續效能評估。

4.2.4 情緒條件化 LoRA 模型

為了後續探討情緒操控線索對詐騙辨識行為的影響，本研究進一步將人工標註後的情緒操控資料作為顯性條件，納入 LoRA 微調模型的輸入設計中。模型除原始文本外，額外接收情緒類型提示，使其在推論時能同時考量語意內容與情緒語境。此設計目的在於，檢驗在相同模型架構與參數規模下，情緒線索是否有效提升模型對隱性詐騙話術的辨識能力。

4.3 實驗數據

4.3.1 LLM 與 ML 在整體詐騙偵測上的效能差異

表三將基準模型、雲端、本地端大型語言模型整合做比較。為確保模型比較的公平性，所有模型皆以相同獨立測試集進行評估，並以統一指標衡量效能差異。

表三、不同模型於詐騙文本辨識任務的整體效能表現

模型	Accuracy	Precision	Recall	F1	Specificity	AUC-ROC	AUC-PR
baseline	0.4815	0.4906	0.9630	0.6500	0.0000	0.5590	0.6242
gemini	0.9444	0.9000	1.0000	0.9474	0.8889	0.9877	0.9883
mistral	0.7963	0.7105	1.0000	0.8308	0.5926	0.9767	0.9808
Qwen	0.9259	0.9600	0.8889	0.9230	0.9630	0.9767	0.9800
Qwen+lora	0.8889	0.9565	0.8148	0.8800	0.9630	0.9808	0.9813
Qwen+lora+emotional	0.9444	0.9000	1.0000	0.9474	0.8889	0.9767	0.9725

根據表三彙整不同模型於詐騙文本辨識任務的整體效能表現，結果顯示語意導向模型在詐騙文本辨識任務的整體判別能力優於以詞頻特徵為主的基準模型，反映詐騙話術在語意變異與隱含意圖的情境之下，僅依賴關鍵字特徵容易產生系統性限制。

(一) 雲端大型語言模型 (Gemini 與 Mistral)

Gemini 模型在本實驗中表現最為穩定，其 Accuracy 為 0.9444，Recall 為 1.0，代表模型能夠完整辨識所有詐騙樣本，幾乎不存在漏判風險。

相較之下，Mistral 雖同樣達到 Recall = 1.0，在詐騙樣本的敏感度表現良好，但其 Precision (0.7105) 與 Specificity (0.5926) 明顯偏低，反映模型在高召回取向下，犧牲了對非詐騙訊息的正確判斷能力，容易產生誤判。

(二) LoRA 微調模型與情緒條件模型


本研究所提出之 LoRA 微調模型在整體表現上展現良好平衡性。其 Precision 達 0.9565，Specificity 為 0.9630，模型在非詐騙樣本的辨識能力顯著優於雲端模型，能有效降低誤判風險。但是 Recall 為 0.8148，說明在極端保守的情境下，仍存在少量詐騙樣本沒有被正確辨識。

第二階段加入情緒條件後的 LoRA emotional 模型，在 Recall 提升至 1.000 的同時，仍然維持與 Gemini 相當的整體準確度 (Accuracy = 0.9444)。表示情緒資訊有助於模型捕捉詐騙文本中隱含的誘導策略，使模型在詐騙偵測任務中展現更高的敏感度。

(三) 基準模型 (Baseline)

相較於上述模型，基準模型 (TF-IDF + Logistic Regression) 整體效能明顯受限，其 Accuracy 僅為 0.4815，模型幾乎無法正確辨識非詐騙樣本。雖然其 Recall 高達 0.9630，代表模型傾向將多數訊息判定為詐騙，但此種極端偏向同一類的分類行為，在實務面的可行性下降。


本研究將從 ROC Curve 與 Precision-Recall 曲線分析決策風險取向，就是在模型分類決策時，對漏判 (FN) 與誤判 (FP) 之間的代價權衡。



圖二、不同模型的 ROC Curve

圖二顯示，大型語言模型與 LoRA 微調模型皆呈現接近 1.000 的曲線下面積，代表模型具有高度穩定的排序能力。在任意決策閾值下，模型都能有效地將詐騙文本的風險分數排序在非詐騙文本之前。相比之下，基準模型的 ROC 曲線接近對角線，AUC 較低，表示其整體區辨能力有限。

ROC 曲線所反映的效能差異並非來自單一決策閾值設定，而是源於模型在整體風險排序與語境判斷能力上的結構性差異。即使在資料分布平衡的條件下，語意導向模型仍然展現出較佳且穩定的判別能力，為後續實務部署中調整決策門檻提供彈性空間。



圖三、不同模型的 Precision-Recall Curve

圖三中雲端大型語言模型在高召回率區間能維持較高的詐騙覆蓋率，但 Precision 隨召回率提升而略有下降，反映模型為避免漏判詐騙而採取較保守的決策方法。相對地，本地端 LoRA 微調模型在中高召回率區段仍能維持較高 Precision，在降低誤判非詐騙訊息方面具備較佳平衡性。基準模型在 PR 曲線上呈現 Precision 急遽下降之趨勢，顯示模型在提升召回率時需大量犧牲精準度。

(四) TOPSIS 分析

考量到單一指標難以全面反映模型表現，本研究應用 TOPSIS 技術分別對 F1 分數、AUC、召回率、精確率和特異性五項評價指標進行綜合測算。首先對原始指標進行歸一化處理以消除尺度差異，然後使用三種不同的權重配置來建立加權歸一化決策矩陣，以進行敏感度分析：

$W1 = [0.3, 0.25, 0.2, 0.15, 0.1]$ ， $W2 = [0.25, 0.25, 0.2, 0.2, 0.1]$ ， $W3 = [0.25, 0.3, 0.2, 0.2, 0.1]$ 。

針對每個場景確定理想解和負理想解，並計算每個模型與這些解的歐氏距離，從而得出接近係數。

表四、模型綜合性能 TOPSIS 評估表

Model	W1	W2	W3	Rank_mean
Gemini	0.9361	0.9249	0.9274	1
Qwen+LoRA+Emo	0.9343	0.9233	0.9252	2
Qwen	0.8928	0.8973	0.9016	3
Qwen+LoRA	0.8164	0.8284	0.8396	4
Mistral	0.6764	0.6578	0.6831	5
Baseline	0.1275	0.1248	0.1213	6

如表四所示，TOPSIS 分析提供了一個綜合評估模型表現的方法，將多個評估指標整合為單一的接近係數。Gemini 在三種權重配置下均取得最高接近係數，在每個情境中均排名第一。其優異的排名主要源於在 F1-score、AUC 及 Recall 等關鍵指標上的平衡表現，表明其在詐騙檢測任務中既具有高度預測準確性，又能可靠地檢測正樣本。

結合 LoRA 與情感特徵的 Qwen 緊隨其後，接近係數分別為 0.9343、0.9233 和 0.9252，排名第二，反映了透過參數高效微調與情感信息的引入，模型能更好地捕捉細微的語意與情緒線索。原始的 Qwen 模型及 Qwen 結合 LoRA 則分別排名第三和第四，雖在部分指標上仍保持良好表現，但缺少情感特徵可能限制了對情境依賴模式的完整理解。Mistral 與基準模型的接近係數明顯較低，分別排名第五和第六，凸顯了大型語言模型在捕捉語意與上下文關係上的優勢，而傳統或小型模型難以達到相同效果。

不同權重配置下排名的穩定性證實了 TOPSIS 方法的健壯性：指標權重的輕微變化不會顯著改變模型的相對排序，說明此評估方法對主觀權重選擇具有良好容忍度。綜合而言，這些結果提供了對模型表現的多維度全面評估，並驗證了基於 LLM 的模型，特別是 Gemini 與 Qwen+LoRA+Emo，在需要語意理解與情緒推理的複雜詐騙檢測任務中展現出優異的效能。

綜合上述，不同模型在詐騙偵測任務中呈現出明顯的風險取向差異。雲端大型語言模型在召回率表現上具有優勢，適合高敏感度需求場景。而本研究提出之 LoRA 微調模型則在精準度與特異度上展現較佳平衡，具備實務部署上的可行性。進一步導入情緒條件後，模型在維持高整體效能的同時提升了對詐騙樣本的敏感度，表示情緒資訊對於詐騙文本辨識提供了實質幫助。

4.3.2 LLM 與傳統機器學習模型在詐騙文本中語意線索擷取與語境推論能力差異

雖然整體分類效能指標可用在評估不同模型於詐騙偵測任務中的表現高低，但是僅憑單一測試集上的準確率或 AUC 指標，仍不足以說明模型在判斷過程中實際所依賴的語言線索。實務上，詐騙話術常刻意迴避明顯警示字詞，轉而透過語境暗示或敘事結構誘導受害者，因此模型是否具備語境推論能力，成為影響詐騙偵測穩健性的關鍵因素。因此，本研究提出研究問題二（RQ2），關注模型在判斷詐騙訊息時，究竟是主要依賴顯性關鍵字，抑或能有效擷取並整合隱含於語境中的語意線索。

為使語意線索顯性程度足夠具體，本研究依據人工標註的詐騙語意型態（scam_semantic_type），將詐騙文本進一步區分為兩類子集合：（1）keyword 型詐騙，指文本中包含明確且常見之詐騙關鍵字；（2）implicit 型詐騙，指文本中未出現明顯警示字詞，而主要仰賴語境暗示或敘事誘導傳達詐騙意圖。

為避免資料分布差異對結果解讀造成干擾，本研究僅於真實標註為詐騙之樣本集合中進行子集合分析，藉此專注比較不同語意型態詐騙在模型辨識難度上的差異。在 RQ2 的設定下，研究重點不在於整體二元分類效能，而在於模型於不同詐騙語意型態下的漏判行為（FN）。因此，本研究將評估範圍聚焦在真實詐騙樣本，並持續以「是否成功辨識為詐騙」作為召回率（Recall）、漏判率（False Negative Rate, FNR）與 F1 分數成為主要分析指標。

本研究於 RQ2 中沿用 RQ1 所使用之模型設定，包含傳統機器學習基準模型、兩種雲端大型語言模型，以及本地端 LoRA 微調模型。所有模型皆於相同資料集與相同推論流程下進行評估，確保子集合分析結果主要反映模型行為差異，而非訓練資料或評估條件所致。

表五、在隱性詐騙詐騙下模型表現

Implicit Scam Subset					
Metric	Baseline	Gemini	Mistral	LoRA	LoRA-Emo
Accuracy	1.000	1.000	1.000	0.556	1.000
Recall	1.000	1.000	1.000	0.556	1.000
F1	1.000	1.000	1.000	0.714	1.000
FNR	0.000	0.000	0.000	0.444	0.000

表六、在關鍵字詐騙下模型表現

Keyword Scam Subset					
Metric	Baseline	Gemini	Mistral	LoRA	LoRA-Emo
Accuracy	0.944	1.000	1.000	0.944	1.000
Recall	0.944	1.000	1.000	0.944	1.000
F1	0.971	1.000	1.000	0.971	1.000
FNR	0.056	0.000	0.000	0.056	0.000

在表五 implicit 詐騙子集合中，傳統基準模型與雲端大型語言模型（Gemini、Mistral）皆能成功辨識所有隱性詐騙樣本，未出現漏判情形。然而，未引入情緒條件之 LoRA 模型在此子集合中表現顯著受限，其召回率僅為 0.556，漏判率高達 0.444，顯示模型在缺乏顯性關鍵字的情境下，難以僅憑文本語意完成有效判斷。

值得注意的是，在相同模型架構下引入情緒條件後（LoRA-Emotional），模型於 implicit 詐騙子集合中的辨識能力顯著改善，召回率提升至 1.000，漏判

率降至 0.000。此結果顯示，情緒線索可作為關鍵資訊，補足語意線索不足時的判斷依據，進而降低隱性詐騙之漏判風險。

在上圖表六 keyword 詐騙子集中，Baseline 與 LoRA（未加 emotional）仍有 5.6%漏判 $FNR=0.056$ 表示即使是 keyword 型詐騙，這兩個模型仍會漏掉一部分樣本。在有顯性線索的情境下，兩者仍呈現較保守決策傾向。當詐騙文本包含明確關鍵字時，多數模型皆能成功擷取顯性語意線索進行判斷。即使未引入情緒條件，基準模型與 LoRA 模型也能維持較高召回表現，漏判情形相對有限。keyword 型詐騙對模型之語境推論需求較低，模型主要可透過表層關鍵字完成判斷，亦解釋為何情緒條件於此子集中的效能提升幅度相對有限。


RQ2 的實驗結果顯示，模型在不同詐騙語意型態下之辨識行為不同。傳統基準模型與未引入情緒條件之 LoRA 模型，於隱性詐騙情境中較易產生漏判，反映其對顯性關鍵字之依賴；相對地，大型語言模型以及引入情緒條件之 LoRA 模型，能有效利用語境與情緒線索補足語意顯性不足之限制，顯著降低隱性詐騙之漏判風險。詐騙偵測效能之差異不僅來自模型規模或訓練資料量，更與模型是否具備語境與情緒層次之推論能力高度相關，並為後續探討情緒操控策略對模型決策影響（RQ3）奠定實證基礎。

4.3.3 情緒操控偵測與情緒類型辨識任務中的模型表現差異

詐騙話術常透過情緒操控策略以影響受害者的判斷行為，例如利用貪婪（greedy）、緊迫感（urgency）或信任建立等方式，引導受害者在資訊不完全的情境下做出不利決策。然而，過往以傳統機器學習為基礎之詐騙偵測研究，多半聚焦於關鍵字或表層語言特徵，較少探討模型是否能有效感知並利用情緒層面的語境線索。

本研究之研究問題三（RQ3）採用分層式分析設計，以探討情緒操控線索對模型詐騙辨識行為的影響。首先，於宏觀層級中，本研究僅考量詐騙文本是否包含情緒操控 emotion_manipulation，使模型知道此文本存在情緒誘導，但未提供具體情緒類型，目的在於觀察模型在情緒操控情境下的整體反應。其次，在微觀層分析中，本研究固定詐騙文本的情緒類型 emotion_type，分別觀察不同模型在特定情緒操控策略下的詐騙辨識行為。此設定使研究可以區分「情緒類型本身是否具有判斷價值」，以及「模型是否具備利用該情緒線索進行決策之能力」。

在分析模型於情緒操控情境下的辨識行為前，先從圖四中檢視詐騙文本中各類情緒操控策略的實際分布情形。在本研究所蒐集之詐騙文本中，可觀察到情緒操控手法具有明顯分布特徵，其中以 greedy 與 urgency 為最常見的情緒類型。



圖四、測試集情緒操控之分布

在 lora 尚未加入 emotional 之前的宏觀層分析中，觀察模型在缺乏情緒語意對齊的情境下，其詐騙辨識行為是否產生變化。

表七、不同模型對是否有隱性情緒的單一標註整體效能表現

	Baseline	Gemini	Mistral	Lora
Recall	0.957	1	1	0.783
F1	0.978	1	1	0.878
FNR	0.043	0	0	0.217
N	23	23	23	23

表七結果顯示，當加入是否有隱性情緒的標註時，通用雲端大型語言模型能較敏感地回應情緒化語境，而基於關鍵字的傳統機器學習模型則無法透過已說明有情緒操控的單一敘述判斷詐騙。相較之下，僅針對詐騙分類任務進行微調但未加入情緒訓練的 LoRA 模型，於部分情緒操控類型中呈現較為保守的決策行為，顯示模型並未自動將情緒訊號視為詐騙判斷的充分依據。

為進一步分析模型於不同情緒操控策略下之行為差異，本研究將情緒操控樣本細分為具體情緒類型進行比較。

表八、不同模型對情緒 greedy 的效能表現

condition-greedy				
Metric	Baseline	Gemini	Mistral	Lora
Recall	1	1	1	0.714
F1	1	1	1	0.833
FNR	0	0	0	0.286
N	7	7	7	7

表九、不同模型對情緒 urgency 的效能表現

condition-urgency				
Metric	Baseline	Gemini	Mistral	Lora
Recall	0.833	1	1	0.833
F1	0.909	1	1	0.909
FNR	0.167	0	0	0.167
N	6	6	6	6

根據表八、表九結果，即使在情緒類型已明確的情境下，未納入情緒類型訓練之 LoRA 模型，仍無法穩定利用情緒操控線索進行詐騙判斷。為進一步驗證情緒線索建模對模型決策行為之影響，本研究將情緒操控資訊納入 LoRA 模型之推論過程，形成情緒條件化 LoRA 模型（lora-emotional-manipulation）。此設定使模型在進行詐騙判斷時，不僅依據文本語意內容，亦能參考對應之情緒操控線索，從而評估情緒條件化設計是否能提升模型於情緒驅動詐騙情境下的辨識穩健性。

表十、不同模型對是否有隱性情緒的單一標註整體效能表現

lora-emotional-manipulation				
	Baseline	Gemini	Mistral	Lora
Recall	0.957	1	1	1
F1	0.978	1	1	1
FNR	0.043	0	0	1
N	23	23	23	23

在表十宏觀層分析中，當情緒操控資訊被顯性納入 LoRA 模型後，其詐騙辨識行為出現明顯改變。相較於未納入情緒資訊時，LoRA 模型於 emotion_manipulation 子集合中的召回率由原先的 0.783 提升至 1.000，漏判率亦由 0.217 降至 0.000，代表模型在僅知悉文本存在情緒操控的情境下，已能有效將情緒線索納入詐騙判斷依據。LoRA 模型之決策行為不再僅依賴表層語言特徵，而能主動將情緒誘導視為詐騙風險訊號，進而降低整體漏判風險。

表十一、兩種 lora 對情緒 greedy 的效能表現

condition-greedy		
Metric	Lora	Lora+emotional
Recall	0.714	1
F1	0.833	1
FNR	0.286	0
N	7	7


表十二、兩種 lora 對情緒 urgency 的效能表現

condition-urgency		
Metric	Lora	Lora+emotional
Recall	0.833	1
F1	0.909	1
FNR	0.167	0
N	6	6

在表十一、十二微觀層分析中，當情緒類型被顯性納入 LoRA 模型後，其在 greedy 與 urgency 兩種主要情緒操控類型中的辨識行為皆趨於穩定。特別是在緊迫感（urgency）類型中，基準模型仍出現漏判情形，而情緒條件化 LoRA 模型則成功補足此缺口，顯示情緒語境的顯性建模能有效提升模型對語境型詐騙線索的感知能力。情緒類型顯性建模不僅能改善整體情緒操控情境下的辨識效能，亦能有效補足模型於特定高誘導性情緒策略中的判斷盲點。

綜合宏觀與微觀層之分析結果可知，情緒條件化設計能一致性地改善 LoRA 模型於情緒操控型詐騙文本中的辨識行為。在宏觀層中，模型僅需知悉文本存在情緒操控，即可顯著降低整體漏判風險；而在微觀層中，透過引入具體情緒類型，模型得以進一步精準掌握不同情緒策略所隱含之詐騙風險。

情緒線索的有效利用並非自然內生於模型結構，而須透過任務導向之條件化設計加以引導。當情緒資訊與訓練任務達成對齊時，即使參數規模較小之 LoRA 模型，亦能於情緒驅動之詐騙偵測任務中展現與大型語言模型相當之穩健性，突顯任務導向微調在實務應用上的潛在價值。



圖五、 Emotion-conditioned LoRA 模型與基準模型於 ROC 與 PR 曲線比較

為進一步驗證情緒條件化設計對模型決策行為之整體影響，本研究補充以 ROC 與 Precision-Recall 曲線進行分析。如圖五所示，Emotion-conditioned LoRA 模型於 ROC 與 PR 曲線下皆呈現顯著優於基準模型之表現，其 AUC 值分別達 0.9767 與 0.9725，顯示模型在不同決策閾值設定下，皆能穩定維持較高之詐騙辨識能力。

相較之下，未納入情緒條件之 TF-IDF 基準模型，其曲線表現接近隨機分類，反映其判斷行為高度依賴特定閾值設定。此結果進一步支持前述 RQ3 的實驗發現，即情緒類型顯性建模不僅改善單一指標表現，亦能從整體決策空間角度提升模型之風險辨識穩健性。

4.3.4 本地端 LLM 與雲端 LLM 在效能、推理速度與成本上的差異

比較雲端 LLM 與本地 LLM 的準確率、推理速度、運算資源需求和成本效益，評估是否有建置本地端微調 LLM 的實際價值。透過實驗驗證不同 LLM 的效能，提供未來防詐騙系統設計的參考依據，以及提高在未來的價值和可塑性，以供企業或其他單位使用。

(一) 支出成本

本地端 Qwen 不需要支付 api 費用，而雲端 llm 研究者以學生方案無須支付費用，但是仍計算出實際 token 搭配官方網站價格估算費用。

本研究從兩個角度說明每個模型的金錢成本：實際計費成本和基於官方定價方案的預估成本。實際計費成本反映了實驗期間產生的實際支出，由於研究者使用了教育免費套餐，Gemini 在實驗期間無需支付任何費用，Mistral 使用的是免費的 api，而基於 LoRa 的本地模型也無需支付任何 API 費用。

為了確保模型之間的公平比較，我們也假設所有雲端模型均採用官方付費定價方案，並以此估算了推理成本。預估成本的計算是基於每個樣本處理的輸入和輸出令牌數量，並乘以各提供者的公開定價。令牌使用量根據相應的分詞器以及完整的推理提示和輸出進行估算。

表十三、雲端大語言模型推估成本

指標	Gemini	Mistral	說明
Mean	0.000486	0.000528	每一筆推論的平均估計成本
Median	0.000485	0.000526	代表「典型一筆」推論的成本，較不受極端值影響
P95	0.000505	0.000563	95% 推論成本不超過此值，反映偏高成本情境
Sum	0.02627	0.028496	完成本次測試資料集之總推論估計成本

本研究之雲端 LLM 推論成本係依每筆推論之 token 使用量，按官方付費單價換算為估計成本；在本次測試資料集上，Gemini 與 Mistral 的總估計成本分別為 0.026270 USD 與 0.028496 USD。

(二) 時間成本

本研究將模型推論的時間成本區分為端到端時間與純推論時間。純推論時間定義為單筆訊息送入模型至取得輸出之耗時，不包含任何為避免 API 限流而

設定的等待時間。端到端時間則包含推論本身及流程中的額外等待，反映實務部署下單筆請求的實際處理時間。研究以 `time.perf_counter()` 逐筆量測並彙整 mean、median 與 P95，以同時呈現平均成本、典型體感與尾端延遲表現。


◆ 端到端時間

端到端時間反映實際跑完整個實驗的時間成本，一次樣本從開始到結束整個流程所花的時間，包含加入防止限流的 `sleep` 處理。由於實際應用情境中，使用者所感知之延遲為端到端推論時間，本研究於時間成本分析中以端到端延遲作為主要比較指標。實驗結果顯示，本地端 Emotion-conditioned LoRA 在端到端時間上不僅平均延遲最低，且於高分位情境下亦維持穩定表現，顯示其具備即時部署之可行性。

表十四、端到端時間成本

	Gemini	Mistral	LoRA	Emotion-conditioned LoRA
LLM_wall_mean_sec	10.7907	2.1727	0.6651	0.2376
LLM_wall_median_sec	10.4499	1.9396	0.646	0.2299
LLM_wall_p95_sec	14.9237	3.7234	0.8615	0.2548
LLM_wall_min_sec	7.0301	1.7608	0.2558	0.2137
LLM_wall_max_sec	25.5787	4.0064	0.9303	0.4203

表十四呈現各模型於端到端推論流程（LLM_wall）下之時間成本統計結果，涵蓋平均值(mean)、中位數(median)、第 95 百分位(p95)以及最小與最大值。由於端到端時間包含前處理、模型推論與後處理，能更真實反映實際部署情境中使用者所感知之延遲。



圖六、端到端時間成本長方圖


透過圖六視覺化呈現，在雲端大型語言模型中，Gemini 的端到端推論時間最長，其平均延遲為 10.79 秒，p95 高達 14.92 秒，最大值達 25.58 秒，顯示其在高分位與極端情境下存在顯著長尾延遲。相較之下，Mistral 雖同屬雲端模型，但其平均端到端時間僅 2.17 秒，p95 為 3.72 秒，整體延遲顯著低於 Gemini。

在本地端模型方面，LoRA 與 Emotion-conditioned LoRA 均展現出顯著較低之端到端延遲。其中，一般 LoRA 的平均端到端時間為 0.67 秒，而 Emotion-conditioned LoRA 進一步下降至 0.24 秒，其 p95 僅 0.25 秒，顯示模型在多數情境下皆能提供穩定且即時的回應。

在 LoRA 和 Emotion-conditioned LoRA 的程式裡，是先用 generate 產生是否為詐騙的判定，再用 loss/softmax 算連續機率。所以本研究獨立呈現生成決策時間與機率估計時間。

表十五、端到端時間的 lora 生成決策時間成本

Generate		
	LoRA	Emotion-conditioned Lora
LLM_generate_mean_sec	0.5796	0.1581
LLM_generate_median_sec	0.5642	0.1455
LLM_generate_p95_sec	0.7531	0.177
LLM_generate_min_sec	0.1771	0.1357
LLM_generate_max_sec	0.8029	0.3273




圖七、端到端時間的 lora 生成決策時間成本長方圖

模型根據輸入 prompt，實際執行語言生成所花費的時間，包含對輸入文本進行語境理解、逐個 token 生成回應和完成一次完整的語言輸出序列。

表十六、端到端時間的 lora 機率估計時間成本

probcalc		
	LoRA	Emotion-conditioned LoRA
LLM_probcalc_mean_sec	0.0855	0.0795
LLM_probcalc_median_sec	0.0809	0.0787
LLM_probcalc_p95_sec	0.1066	0.0848
LLM_probcalc_min_sec	0.0758	0.0758
LLM_probcalc_max_sec	0.1273	0.0931



圖八、端到端時間的 lora 機率估計時間成本長方圖

在生成完成後，lora 模型對既有輸出進行機率計算或分類判斷的時間。包括計算「是否為詐騙」的機率或信心分數。

推論時間拆解結果顯示，生成階段為整體延遲的主要來源。表十五、圖七為顯示相較於一般 LoRA 模型，Emotion-conditioned LoRA 在生成階段的平均時間由 0.58 秒降至 0.16 秒，於 p95 情境下僅須 0.18 秒，表示其在生成過程中具備顯著較低且穩定的延遲表現。於機率計算階段，透過表十六、圖八，為兩種模型皆維持低延遲水準，且 Emotion-conditioned LoRA 於高分位情境下仍呈現較佳穩定性。根據結果顯示，情緒條件化設計不僅未增加模型計算負擔，反而能有效降低生成階段的推論延遲。此一現象可能源於情緒資訊被顯性提供後，模型在生成過程中不需進行隱性語境推論，從而縮短生成路徑並提升推論效率。綜合生成與機率計算時間之分析結果可知，Emotion-conditioned LoRA 在


維持甚至提升辨識效能的同時，於推論效率與穩定性上亦展現顯著優勢，顯示情緒條件化設計可同時改善模型之決策品質與系統效能。

◆ 純推論時間

純推論時間為參考，同時釐清不同模型時間成本之來源，本文另分析純模型推論時間。結果顯示，Emotion-conditioned LoRA 於純推論階段未引入額外計算負擔，顯示情緒條件化設計本身並非造成延遲之主因。

表十七、純推論時間成本

	Gemini	Mistral	LoRA	Emotion-conditioned LoRA
LLM_infer_mean_sec:	9.7835	1.1653	0.6651	0.2376
LLM_infer_median_sec	9.4437	0.9320	0.6460	0.2299
LLM_infer_p95_sec:	13.9150	2.7217	0.8615	0.2548
LLM_infer_min_sec	6.0204	0.7548	0.2558	0.2136
LLM_infer_max_sec:	24.5722	3.0057	0.9303	0.4203



圖九、純推論時間比較成本長方圖

結論

本研究以「大型語言模型應用於詐騙偵測」為核心主題，系統性比較傳統機器學習方法、雲端大型語言模型以及本地端參數高效化微調模型，在不同詐騙語境與應用條件下的辨識效能、決策行為差異與實務部署可行性。相較於既有研究多聚焦於單一模型效能或整體準確率指標，本研究進一步從語意線索顯性程度、情緒操控語境以及時間與成本等系統層面因素，提出分層且可驗證的實證分析框架，藉此回應詐騙話術日益隱晦化與情緒化的現實挑戰。

首先，在整體詐騙偵測效能（RQ1）方面，語意導向模型相較於僅依賴詞頻特徵之傳統機器學習模型，於詐騙文本辨識任務中具有顯著優勢。基準模型雖能在高召回取向下涵蓋多數詐騙樣本，但其對非詐騙文本的誤判率偏高，反映出以表層關鍵字為主的判斷策略在語意變異與話術包裝日益複雜的情境下，存在結構性限制。相對地，雲端大型語言模型（Gemini、Mistral）與本地端 LoRA 微調模型，皆能透過語境理解與語意推論，有效提升整體分類穩定度，顯示大型語言模型在詐騙偵測任務中具備明確的方法論價值。

其次，在語意線索擷取能力（RQ2）之分析中，本研究透過將詐騙文本區分為 keyword 與 implicit 兩種語意型態，進一步揭示不同模型於顯性與隱性詐騙情境下的行為差異。實驗結果顯示當詐騙文本包含明確關鍵字時，多數模型皆能穩定完成判斷；然而在缺乏顯性警示字詞、需仰賴語境暗示的 implicit 詐騙情境中，模型表現出顯著分化。未引入情緒條件之 LoRA 模型於此子集合中出現較高漏判率，顯示即便具備語言生成能力，若訓練任務未與高階語境線索對齊，模型仍可能回退至偏向表層語意的判斷模式。相對地，雲端大型語言模型與情緒條件化 LoRA 模型，則能有效降低隱性詐騙之漏判風險，突顯語境推論能力在現代詐騙偵測中的關鍵角色。

進一步地，在情緒操控相關分析（RQ3）中，本研究採用宏觀與微觀雙層次設計，分別探討僅知悉文本存在情緒操控以及明確納入情緒類型資訊對模型決策行為之影響。實驗結果顯示，當僅於宏觀層級提供 emotion_manipulation 資訊時，雲端大型語言模型仍能維持高敏感度表現，而未引入情緒條件的 LoRA 模型則呈現較為保守的決策行為，反映模型並未自動將情緒線索視為詐騙風險的重要依據。然而，當情緒類型（emotion_type）被納入 LoRA 模型之訓練與推論條件後，其在整體情緒操控子集合以及 greedy、urgency 等高誘導性情緒類型中，皆顯著改善漏判情形，並達到與雲端大型語言模型相當的辨識穩

健性。

此一結果顯示，情緒線索的有效利用並非模型規模自然帶來的副產物，而高度仰賴任務設計是否能引導模型將情緒視為具有決策價值的語用訊號。當情緒資訊與訓練目標達成對齊（task alignment）時，即使參數規模相對較小的 LoRA 微調模型，仍能在情緒驅動的詐騙情境中展現高度競爭力，說明情緒條件化設計在詐騙偵測任務中的實質貢獻。

最後，在實務部署層面（RQ4），本研究從效能、時間成本與金錢成本三個面向，全面比較雲端與本地端大型語言模型的可行性。實驗結果顯示，雖然雲端大型語言模型在辨識效能上表現穩定，但其端到端推論時間存在顯著長尾延遲，於即時防詐應用中可能構成潛在風險。相對地，本地端 LoRA 與情緒條件化 LoRA 模型不僅在推論效能上具備競爭力，其端到端延遲亦呈現數量級上的優勢，且時間分布高度集中，顯示其在即時系統中具備較佳的穩定性與可預測性。配合本地端模型在金錢成本上的近乎零邊際支出，此結果進一步支持透過參數高效化微調策略，建置可長期運行且具擴展性的防詐系統之可行性。

綜上所述，本研究證實詐騙偵測效能的提升，並非僅取決於模型規模或單一效能指標，而須同時考量語意線索顯性程度、情緒操控語境、決策風險取向以及系統層面的時間與成本限制。透過引入情緒條件化設計與任務導向微調策略，本研究展示了一條在效能、效率與實務可行性之間取得平衡的技術路徑。研究成果不僅補足現有詐騙偵測文獻中對情緒語用線索探討不足之處，亦為未來在高風險語境下部署大型語言模型提供具體且可操作的實證依據。

不同於以往研究僅關注整體準確率，本研究提出了區分顯性/隱性線索與宏觀/微觀情緒的分析角度，可作為在詐騙偵測領域的一種實驗設計。本研究揭示了情緒作為一種高階語用訊號在詐騙偵測中的作用，證實了情緒條件化設計能有效強化參數規模較小之模型的決策效能，為小模型、深度理解的研究方向提供了理論支持。

本研究對於資安防禦與企業部署具有高度參考價值，針對即時防詐需求，本研究提供完整的效能-成本效益比分析，證實本地端 LoRA 微調方案為兼顧數據隱私、反應速度與運算成本的最佳實踐路徑，協助企業打破對高昂雲端 API 的依賴。實務開發者可參考本研究提出的情緒類型納入訓練目標之方法，針對特定話術，例如：催促、威脅進行精準攔截，這對於提升現有通訊軟體或金融警示系統的精準度具有很大的幫助。

本研究之限制與未來研究方向

本研究雖已系統性探討大型語言模型與情緒條件化設計於詐騙文本辨識任務中的效能與實務可行性，仍存在若干限制，並據此提出未來研究方向。

一、資料多樣性與代表性仍有限

本研究主要使用已標註之詐騙與非詐騙文本資料進行分析，雖涵蓋不同語意型態與情緒操控策略，但在資料來源與場景上仍以靜態文本為主。未來研究可擴展至社群媒體貼文、即時通訊對話或跨國詐騙案例，並納入多語言或跨文化資料，以評估模型於不同語言環境與詐騙話術演化下的泛化能力與穩健性。

二、情緒標註方式與情緒類型定義仍有進一步深化空間

本研究以人工標註之情緒操控與情緒類型作為模型條件化資訊，雖已證實其對詐騙辨識具正向效果，但情緒類型的分類仍屬有限集合。未來可結合心理學或語用學理論，發展更細緻或連續型的情緒表示方式，或透過半監督與自監督方法降低情緒標註成本，進一步提升模型對複合型情緒操控策略的辨識能力。

三、TOPSIS 方法與決策閾值

本研究在使用 TOPSIS 方法進行模型綜合排名時存在若干限制：首先，指標權重設定具有主觀性，雖可透過敏感度分析檢驗排名穩健性，但最終結果仍可能受權重影響。其次，TOPSIS 假設各指標獨立，而 Precision、Recall 與 F1-score 之間高度相關，可能導致接近係數偏向特定模型；此外，該方法僅反映相對排序，對極端值敏感，無法量化絕對性能差距。最後，本研究採用固定決策閾值進行分類，用以比較模型在相同設定下的行為，但在實務情境中，不同使用者或風險場景對漏判與誤判的容忍度不同，未來可結合動態閾值與風險分級策略，使模型依據實際情境調整決策風險取向。

四、模型行為解釋性仍有待加強

雖然本研究已透過情緒條件化設計提升模型於情緒操控型詐騙中的穩健性，但模型在不同情緒語境下的內部決策機制仍屬黑箱。未來可結合可解釋人工智慧（XAI）方法，分析模型在不同語意與情緒條件下所關注的語言特徵，以提升系統在高風險應用場景中的可信度與可審計性。

五、時間延遲與部署環境差異

就時間延遲來說，其實越熱門的 LLM，使用人數越多，所以像 OpenRouter 這樣的服務可能都會降低使用的機器等級，也會造成計算時間較高的現象。未來研究可透過在相同硬體環境下部署模型，或建立可控制的網路環境，以更精確地分離模型運算時間與網路傳輸時間，進一步提升時間評估的準確性。

六、實務部署與長期運行效能仍需驗證

本研究之實驗主要在離線測試資料集上進行，尚未涵蓋詐騙話術隨時間演化的影響。未來可進一步於實際系統中進行長期測試，評估模型於概念漂移（concept drift）情境下的效能變化，並探討持續學習或增量式微調策略，以維持模型對新型詐騙手法的適應能力。

七、多模態 ai 代理

本研究採用單一模型進行判斷，尚未導入多模型協作機制，未來發展願景希望擴展為多模態 ai 代理，融合多個專精於不同領域的小模型，例如專門處理關鍵字的模型融合專精於情緒分析的模型，可再搭配語音便辨識功能作為提升系統能力之手段。核心目標在於透過跨模態的感知與決策能力，有效應對生成式 AI 時代下日益複雜的詐騙威脅，並進一步賦予 AI 代理主動進行風險分析、溝通互動與安全防禦任務執行之能力，以提升在實務應用中的即時性與防護效能。

綜合而言，這些限制與未來方向不僅提供後續研究的明確路徑，亦凸顯情緒條件化與任務導向微調在詐騙偵測領域中的延展潛力。透過持續擴充資料來源、深化情緒建模與強化系統層設計，未來研究可進一步提升詐騙偵測模型於真實應用環境中的實務價值。

未來研究若能結合跨場景資料、多層次情緒建模與動態決策策略，將有助於建構兼具高辨識效能、低延遲與高可解釋性的詐騙防護系統。

參考文獻

王厚勛. (2020). 基於詐騙偵測模型與詐騙事件分類模型的反詐騙聊天機器人之研發. [碩士論文, 國立中興大學] 臺灣博碩士論文知識加值系統。

<https://hdl.handle.net/11296/cxsdmw>

池晉煒 (2022)。竟是一場空:網路愛情詐騙被害歷程之研究。[碩士論文。中央警察大學] 臺灣博碩士論文知識加值系統。

<https://hdl.handle.net/11296/4x49tn>

李佩嫻、顧以謙 (2023) 司法官學院犯罪防治研究中心, 111 年犯罪狀況及其分析-李佩嫻、顧以謙, 愛情詐欺之犯罪模式及防制策略。

<https://www.cprc.moj.gov.tw/1563/1595/1601/1603/40654/post>

陳恩齊 (2019)。中文斷詞方法對情感分析的影響 [碩士論文, 淡江大學] 臺灣博碩士論文知識加值系統。 <https://hdl.handle.net/11296/vvgb4b>

陳怡文 (2021)。詐欺型態與預防作為之分析。[碩士論文。輔仁大學] 臺灣博碩士論文知識加值系統。 <https://hdl.handle.net/11296/58qkf7>。

內政部警政署 (2024), 警政統計通報 (113 年第 14 週)

<https://www.npa.gov.tw/ch/app/data/doc?module=wg057&detailNo=1224599461083222016&type=s>

Ali, A., Abd Razak, S., Othman, S. H., Eisa, T. A. E., Al-Dhaqm, A., Nasser, M., ... & Saif, A. (2022). Financial fraud detection based on machine learning: a systematic literature review. *Applied Sciences*, 12(19), 9637.

Behzadian, M., Otaghsara, S. K., Yazdani, M., & Ignatius, J. (2012). A state-of-the-art survey of TOPSIS applications. *Expert Systems with applications*, 39(17), 13051-13069.

Chakraborty, J., Xia, W., Majumder, A., Ma, D., Chaabene, W., & Janvekar, N. (2024). Detoxbench: Benchmarking large language models for multitask fraud & abuse detection. *arXiv preprint arXiv:2409.06072*.

Guo, J., Wei, J., Cheng, Y., Sheng, J., Wu, Y., & Sato, K. (2026, January). Runtime Prediction for Local Deployment of Large Language Models: A Case Study on Qwen Models Covering LoRA Fine-Tuning, RAG, and Inference. In *Proceedings of the Supercomputing Asia and International Conference on High Performance Computing in Asia Pacific Region Workshops* (pp. 361-369).

Han, T., Fang, C., Zhao, S., Ma, S., Chen, Z., & Wang, Z. (2024). *Token-Budget-Aware LLM Reasoning*. arXiv preprint arXiv:2412.18547.

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... & Chen, W. (2021). Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*.

Hwang, C. L., & Yoon, K. (1981). *Multiple attribute decision making: Methods and applications*. Springer-Verlag.

Ji, F., & Kim, D. (2025). How Can We Effectively Use LLMs for Phishing Detection?: Evaluating the Effectiveness of Large Language Model-based Phishing Detection Models. *arXiv preprint arXiv:2511.09606*.

Li, M., Sun, J., & Tan, X. (2024). *Evaluating the effectiveness of large language models in abstract screening: A comparative analysis*. Systematic Reviews, 13(1), 219.

Papasavva, A., Johnson, S., Lowther, E., Lundrigan, S., Mariconti, E., Markovska, A., & Tuptuk, N. (2024). Application of AI-based Models for Online Fraud Detection and Analysis. *arXiv preprint arXiv:2409.19022*.

Sun, J. W., Bao, J. Q., & Bu, L. P. (2022, February). Text classification algorithm Based on TF-IDF and BERT. In *2022 11th International Conference of Information and Communication Technology (ICTech)* (pp. 1-4). IEEE.

Surikova, E. V., & Sabidaeva, E. A. Comparative Study of LoRA and Full Fine-Tuning in Large Language Models.

Yoon, S. (2023). Design and Implementation of an LLM system to Improve Response Time for SMEs Technology Credit Evaluation. *International Journal of Advanced Smart Convergence*, 12(3), 51–60.